

Lista 4  
Finanças Quantitativas  
Diogo Wolff Surdi

## Questão 3.17

### 17.1

Note que, pela LOTUS, temos:

$$\begin{aligned}\mathbb{E}[f(Z)e^{\sigma Z}] &= \int \frac{f(x)}{\sqrt{2\pi}} e^{\sigma x} e^{-\frac{x^2}{2}} dx \\ &= \int \frac{f(x)}{\sqrt{2\pi}} e^{\sigma x - \frac{x^2}{2}} dx \\ &= \int \frac{f(x)}{\sqrt{2\pi}} e^{\frac{2\sigma x - x^2}{2}} dx\end{aligned}$$

Completando os quadrados, temos:

$$\begin{aligned}2\sigma x - x^2 &= 2\sigma x - x^2 + \sigma^2 - \sigma^2 \\ &= -(x - \sigma)^2 + \sigma^2\end{aligned}$$

Logo:

$$\begin{aligned}\mathbb{E}[f(Z)e^{\sigma Z}] &= \int \frac{f(x)}{\sqrt{2\pi}} e^{\frac{-(x-\sigma)^2 + \sigma^2}{2}} \\ &= \int \frac{f(x)}{\sqrt{2\pi}} e^{\frac{\sigma^2}{2}} e^{-\frac{(x-\sigma)^2}{2}} \\ &= e^{\frac{\sigma^2}{2}} \int \frac{f(x)}{\sqrt{2\pi}} e^{-\frac{(x-\sigma)^2}{2}}\end{aligned}$$

Note que a expressão da integral é a de uma normal com média  $\sigma$ . Com isso, a integral (e por consequência o valor esperado) são transladados em relação à distribuição  $Z$ , logo:

$$\mathbb{E}[f(Z)e^{\sigma Z}] = e^{\frac{\sigma^2}{2}} \mathbb{E}[f(Z + \sigma)]$$

Para a segunda parte, basta notar que  $Z = \frac{(X-\mu)}{\sigma}$ , donde temos:

$$\mathbb{E}[e^X] = \mathbb{E}[e^{\sigma Z + \mu}] = e^{\mu} \mathbb{E}[e^{\sigma Z}] = e^{\mu + \frac{\sigma^2}{2}} \mathbb{E}[1] = e^{\mu + \frac{\sigma^2}{2}}$$

## 17.2

### Questão 3.18

#### 18.1

Temos que  $X = e^Y$  onde  $Y \sim N(\mu, \sigma^2)$ . Com isso temos:

$$F_X(x) = P(X \leq x) = P(e^Y \leq x) = P(Y \leq \ln x) = F_Y(\ln x)$$

Note que:

$$f_Y(y) = \frac{\partial}{\partial y} F_X(x) = \frac{\partial}{\partial y} F_Y(\ln x) = \frac{1}{x} f_Y(\ln x)$$

Como  $Y$  é normal, temos que:

$$f_Y(y) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y-\mu)^2}{\sigma^2}\right)$$

Logo:

$$f_X(x) = \frac{1}{x} \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(\ln x - \mu)^2}{\sigma^2}\right)$$

Para a questão, tomaremos que  $X$  é log-normal  $(0, 1)$  e  $Y$  é log-normal  $(0, \sigma^2)$ . Ademais, sabe-se que  $\rho_{min} = \rho$  para variáveis contramonotônicas, enquanto que  $\rho_{max} = \rho$  para variáveis comonotônicas.

#### 18.2

Para esse item, note que a função exponencial é estritamente crescente, logo  $\rho_{min} = \rho(e^Z, e^{-\sigma Z})$ . Ademais, pela questão 3.17 temos que  $\mathbb{E}[e^Z] = e^{\frac{1}{2}}$  e  $\mathbb{E}[e^{2Z}] = e^2$ , donde  $Var(e^Z) = e^2 - e = e(e-1)$ . Vale resultado equivalente para  $e^{-\sigma Z}$ , donde  $Var(e^{-\sigma Z}) = e^{\sigma^2}(e^{\sigma^2} - 1)$ . Para a covariância, temos que:

$$\begin{aligned} cov(e^Z, e^{-\sigma Z}) &= \mathbb{E}[e^{(1-\sigma)Z}] - \mathbb{E}[e^Z]\mathbb{E}[e^{-\sigma Z}] \\ &= e^{\frac{(1-\sigma)^2}{2}} - e^{\frac{\sigma^2+1}{2}} \\ &= e^{\frac{1-2\sigma+\sigma^2}{2}} - e^{\frac{\sigma^2+1}{2}} \\ &= e^{\frac{\sigma^2+1}{2}}(e^{-\sigma} - 1) \end{aligned}$$

Com isso, temos que:

$$\rho_{min} = \frac{e^{\frac{\sigma^2+1}{2}}(e^{-\sigma} - 1)}{\sqrt{e(e-1)e^{\sigma^2}(e^{\sigma^2} - 1)}} = \frac{e^{-\sigma} - 1}{\sqrt{(e-1)(e^{\sigma^2} - 1)}}$$

## 18.3

Para encontrar  $\rho_{max}$  basta substituir  $e^{-\sigma Z}$  nas contas do item anterior por  $e^{\sigma Z}$ . Com isso, encontramos  $cov(e^Z, e^{\sigma Z}) = e^{\frac{\sigma^2+1}{2}}(e^\sigma - 1)$ , donde:

$$\rho_{max} = \frac{e^\sigma - 1}{\sqrt{(e-1)(e^{\sigma^2} - 1)}}$$

## 18.4

Para o limite negativo, temos que o numerador tende a 0, enquanto o denominador tende a infinito, logo o limite inferior se aproxima do 0. Para o limite positivo usarei l'Hopital:

$$\lim_{\sigma \rightarrow \infty} \rho_{max} = \lim_{\sigma \rightarrow \infty} \frac{\sqrt{(e-1)(e^{\sigma^2} - 1)}}{(e-1)\sigma e^{\sigma^2-1}}$$

Os termos do numerador são a raiz de termos do denominador, e este é multiplicado por  $\sigma$ , logo o limite também é 0.

## Questão 3.24

### 24.1

Primeiramente, vou utilizar o pacote copula para gerar amostras de cópulas gaussianas bi-dimensionais. O código envolve a mesma linha 21 vezes (uma para cada  $\rho$ ) pois não consegui encontrar um meio de usar um for que gerasse as 21 cópulas, então vou apresentar apenas uma amostra como exemplo.

```
SD7 <- rCopula(2000, normalCopula(0.3))
```

```
> head(SD7)
[ ,1]      [ ,2]
[1 ,] 0.5579378 0.45877269
[2 ,] 0.6831545 0.29538059
[3 ,] 0.3872245 0.40120215
[4 ,] 0.1027863 0.09106661
[5 ,] 0.9828730 0.78213367
[6 ,] 0.5544919 0.36428488
```

Não consegui transformar diretamente as amostras originais em amostras normais, então gerei uma distribuição normal multivariada a partir da cópula gaussiana, e tomarei amostras dela.

### 24.1.2

A função normalCopula não aceitou  $\rho = 1$ , então omiti tal valor do código para gerar a matriz de correlações.

```

rho <- matrix(nrow=20, ncol=1)
corr1 <- matrix(nrow=20, ncol=3)
rho[1,1]<-0

for (i in 2:20){
rho[i,1] <- rho[i-1,1]+0.05
}


corr1 <- matrix(nrow=20, ncol=3)
for (i in 1:20){
teste<-mvdc(normalCopula(rho[i, 1]), c("norm","norm"), list(list(mean=0,sd=1)
steste <- rMvdc(2000,teste)
corr1[i,1] <- cor(steste[,1], steste[,2], method = "pearson")
corr1[i,2] <-cor(steste[,1], steste[,2], method = "kendall")
corr1[i,3] <-cor(steste[,1], steste[,2], method = "spearman")
}

> corr1
[,1]      [,2]      [,3]
[1,] 0.01361288 0.01363082 0.02021014
[2,] 0.05848784 0.03716758 0.05558875
[3,] 0.08624170 0.05600400 0.08389410
[4,] 0.17002320 0.10107954 0.15153448
[5,] 0.14998081 0.09425913 0.14126141
[6,] 0.28896133 0.18390295 0.27052811
[7,] 0.31942075 0.20655828 0.30566670
[8,] 0.35826540 0.23157679 0.33970540
[9,] 0.41636563 0.26872536 0.39386114
[10,] 0.43619186 0.28496248 0.41689367
[11,] 0.49715565 0.32924562 0.47675354
[12,] 0.58341591 0.39144972 0.55838591
[13,] 0.60893375 0.41523462 0.58786938
[14,] 0.67354596 0.46912656 0.65318661
[15,] 0.70193300 0.49269935 0.68200879
[16,] 0.74165283 0.53452626 0.73066192
[17,] 0.80031170 0.59771386 0.79263630
[18,] 0.83958837 0.63518359 0.82851901
[19,] 0.89897045 0.71474837 0.89411035
[20,] 0.95177617 0.80140070 0.94755141

```

### 24.1.3


```
plot(corr1[,1],rho)
```



A correlação de Pearson amostral é bem próxima da correlação entre as próprias distribuições, o que indica que ela é uma boa aproximação para a correlação real.

#### 24.1.4

```
par(mfrow=c(1,2))
plot(corr1[,2], rho)
plot(corr1[,3], rho)
```



A correlação de Kendall (a esquerda) é bem menor do que  $\rho$ , indicando uma subestimação. Por outro lado, a correlação de Spearman apresenta valores parecidos com os reais, sendo muito próxima da de Pearson.

### 24.1.5

Utilizarei técnica parecida à utilizada anteriormente para simular.

```
rho <- matrix(nrow=20, ncol=1)
corr1 <- matrix(nrow=20, ncol=3)
rho[1,1]<-0

for (i in 2:20){
rho[i,1] <- rho[i-1,1]+0.05
}

corr1 <- matrix(nrow=20, ncol=3)
corrteste <- matrix(nrow=20, ncol=3)
for (i in 1:20){
teste<-mvdc(normalCopula(rho[i, 1]), c("cauchy", "cauchy"),
            list(list(location=0,scale=1),list(location=0,scale=1)))
steste <- rMvdc(2000,teste)
corr1[i,1] <- cor(steste[,1], steste[,2], method = "pearson")
corr1[i,2] <-cor(steste[,1], steste[,2], method = "kendall")
corr1[i,3] <-cor(steste[,1], steste[,2], method = "spearman")
}


> corr1
[,1]      [,2]      [,3]
[1,] 0.0003204695 0.02159180 0.03218481
```

```

[2,] 0.0015514021 0.04519960 0.06845508
[3,] 0.0427751172 0.05531766 0.08249222
[4,] 0.0020750534 0.09256128 0.13774839
[5,] 0.0062130510 0.12355778 0.18435948
[6,] 0.0106826023 0.18033017 0.26866075
[7,] 0.0163773965 0.18142471 0.26915943
[8,] 0.0346628899 0.21788894 0.32245153
[9,] 0.0404871733 0.27960680 0.40816775
[10,] 0.0281987449 0.31348874 0.45766505
[11,] 0.0840381248 0.33316558 0.47955629
[12,] 0.0168159062 0.36040020 0.51819141
[13,] 0.1218430095 0.41603802 0.58732821
[14,] 0.0170899157 0.45152276 0.63208668
[15,] 0.1123800567 0.47968284 0.66415262
[16,] 0.7907183573 0.53235018 0.72399542
[17,] 0.2938429648 0.59296448 0.78777492
[18,] 0.3745318990 0.65978989 0.84870474
[19,] 0.4327866148 0.71124762 0.89118737
[20,] 0.8860640464 0.79292346 0.94136547


```

```
plot(corr1[,1], rho)
```



Como a distribuição de Cauchy tem variância indefinida, a correlação de Pearson não é definida, gerando um gráfico absurdo.

```
par(mfrow=c(1,2))
plot(corr1[,2], rho)
plot(corr1[,3], rho)
```



## 24.2

```
SD7item2 <- rCopula(2000, gumbelCopula(4))
```

```
> head(SD7item2)
[,1]      [,2]
[1,] 0.03195630 0.02935435
[2,] 0.91934056 0.92616983
[3,] 0.16524291 0.19554693
[4,] 0.06821096 0.22524028
[5,] 0.84559711 0.79911042
[6,] 0.12534141 0.23590344
```

A função não estava aceitando  $\beta = 1$ , então fiz a simulação a partir de 1.5.

### 24.2.2

```
beta <- matrix(nrow=40, ncol=1)
corr2 <- matrix(nrow=40, ncol=3)
beta[1,1]<-1.5
```



```

for (i in 2:40){
beta[i,1] <- beta[i-1,1]+0.5
}

corr2 <- matrix(nrow=40, ncol=3)
for (i in 1:40){
teste<-mvdc(gumbelCopula(beta[i, 1]), c("norm", "norm"),
            list(list(mean=0,sd=1),list(mean=0,sd=1)))
steste <- rMvdc(2000, teste)
corr2[i,1] <- cor(steste[,1], steste[,2], method = "pearson")
corr2[i,2] <-cor(steste[,1], steste[,2], method = "kendall")
corr2[i,3] <-cor(steste[,1], steste[,2], method = "spearman")
}

```

```


> corr2
[,1]      [,2]      [,3]
[1,] 0.4841239 0.3170245 0.4520041
[2,] 0.6985825 0.5026743 0.6855712
[3,] 0.8087388 0.6132176 0.8018156
[4,] 0.8694131 0.6795588 0.8599238
[5,] 0.8891731 0.7116788 0.8860809
[6,] 0.9174385 0.7531456 0.9125828
[7,] 0.9342931 0.7801911 0.9303695
[8,] 0.9453167 0.8007354 0.9441780
[9,] 0.9501150 0.8085293 0.9483521
[10,] 0.9635278 0.8354277 0.9618726
[11,] 0.9680397 0.8453977 0.9659678
[12,] 0.9723533 0.8613437 0.9723919
[13,] 0.9749077 0.8674047 0.9746959
[14,] 0.9761486 0.8710005 0.9759165
[15,] 0.9792439 0.8773497 0.9781822
[16,] 0.9819783 0.8865633 0.9813451
[17,] 0.9837854 0.8930235 0.9828347
[18,] 0.9854378 0.8975178 0.9848014
[19,] 0.9879013 0.9077909 0.9875759
[20,] 0.9880199 0.9064062 0.9869236
[21,] 0.9890287 0.9136548 0.9891265
[22,] 0.9906501 0.9186833 0.9902370
[23,] 0.9902013 0.9163772 0.9898050
[24,] 0.9919471 0.9220510 0.9909811
[25,] 0.9925980 0.9279590 0.9924673
[26,] 0.9929252 0.9323272 0.9934010
[27,] 0.9928344 0.9298989 0.9926955
[28,] 0.9934974 0.9345893 0.9936310
[29,] 0.9946701 0.9381641 0.9944047

```

```
[30,] 0.9937218 0.9352936 0.9939064
[31,] 0.9947550 0.9398119 0.9945370
[32,] 0.9947449 0.9404392 0.9948661
[33,] 0.9951400 0.9421241 0.9949801
[34,] 0.9955398 0.9443522 0.9953427
[35,] 0.9956614 0.9443452 0.9953375
[36,] 0.9957389 0.9458529 0.9957555
[37,] 0.9959994 0.9475998 0.9959650
[38,] 0.9962712 0.9490975 0.9961891
[39,] 0.9965812 0.9516678 0.9966112
[40,] 0.9966961 0.9518719 0.9966159
```

### 24.2.3

```
plot(corr2[,1], beta)
```

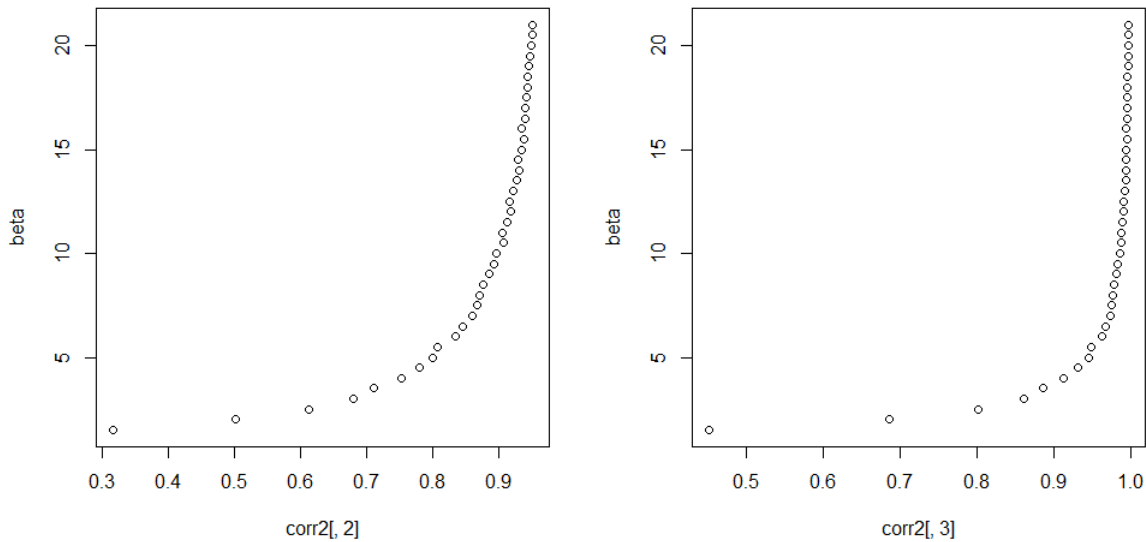


### 24.2.4

Vou notar aqui que a questão fala para plotar em relação a  $\rho$ , porém não vi ele em momento algum no código para esse item.

```
par(mfrow=c(1,2))
plot(corr2[,2], beta)
```

```
plot(corr2[,3], beta)
```



### 24.2.5

```
beta <- matrix(nrow=40, ncol=1)
corr2 <- matrix(nrow=40, ncol=3)
beta[1,1]<-1.5
```


```
for (i in 2:40){
  beta[i,1] <- beta[i-1,1]+0.5
}
```

```
corr2 <- matrix(nrow=40, ncol=3)
for (i in 1:40){
  teste<-mvdc(gumbelCopula(beta[i, 1]), c("cauchy","cauchy"), list(list(location
  steste <- rMvdc(2000, teste)
  corr2[i,1] <- cor(steste[,1], steste[,2], method = "pearson")
  corr2[i,2] <- cor(steste[,1], steste[,2], method = "kendall")
  corr2[i,3] <- cor(steste[,1], steste[,2], method = "spearman")
}
```



```
> corr2
[,1]      [,2]      [,3]
[1,] 0.1210999 0.3497419 0.5019227
[2,] 0.6251803 0.5028414 0.6859553
[3,] 0.2237671 0.5930195 0.7805388
```

[4 ,]	0.6469954	0.6603422	0.8435572
[5 ,]	0.4243963	0.7060950	0.8801649
[6 ,]	0.9296202	0.7556368	0.9157404
[7 ,]	0.3499351	0.7781721	0.9299968
[8 ,]	0.5573221	0.7912826	0.9383118
[9 ,]	0.3810059	0.8219040	0.9540346
[10 ,]	0.9327899	0.8340830	0.9603272
[11 ,]	0.8739633	0.8456118	0.9658818
[12 ,]	0.8149914	0.8555718	0.9703449
[13 ,]	0.6515025	0.8678179	0.9747851
[14 ,]	0.9195109	0.8740210	0.9772441
[15 ,]	0.8122903	0.8781581	0.9783342
[16 ,]	0.5912713	0.8895418	0.9825803
[17 ,]	0.7925018	0.8912786	0.9830939
[18 ,]	0.9824630	0.9032806	0.9859863
[19 ,]	0.8337141	0.9074177	0.9875277
[20 ,]	0.9687268	0.9105173	0.9885130
[21 ,]	0.9825492	0.9135378	0.9891313
[22 ,]	0.9999566	0.9163892	0.9897519
[23 ,]	0.9381691	0.9197699	0.9905660
[24 ,]	0.9129899	0.9233697	0.9913949
[25 ,]	0.8885618	0.9209725	0.9908799
[26 ,]	0.9068627	0.9317719	0.9932258
[27 ,]	0.9873727	0.9284342	0.9925223
[28 ,]	0.9709242	0.9290975	0.9926489
[29 ,]	0.9513847	0.9349995	0.9937814
[30 ,]	0.9765138	0.9352386	0.9937918
[31 ,]	0.9583998	0.9399480	0.9945806
[32 ,]	0.8566301	0.9392076	0.9944964
[33 ,]	0.9851596	0.9413567	0.9948874
[34 ,]	0.9992662	0.9433007	0.9951582
[35 ,]	0.9971951	0.9456718	0.9956199
[36 ,]	0.9633900	0.9489045	0.9960840
[37 ,]	0.9960910	0.9503242	0.9964174
[38 ,]	0.9581234	0.9509895	0.9963290
[39 ,]	0.9958326	0.9525063	0.9967073
[40 ,]	0.9938028	0.9537349	0.9968524

```
plot(corr2[,1], beta)
```




```
par(mfrow=c(1,2))
plot(corr2[,2], beta)
plot(corr2[,3], beta)
```



A análise aqui é semelhante à do item 1.5


## Análise

```
precos <- prices_Swap_PRE_DI
precos.pca <- princomp(precos[2:11])
plot(precos.pca,
     main = 'Proporções da Variação explicada pelos componentes')
```



Como pode-se ver, as variações são explicadas quase em sua totalidade pelos três primeiros componentes.

```
X <- c(48,1,60,2,3,4,6,12,24,36)
par(mfrow=c(2,2))
plot(X, precos.pca$loadings[,1], ylim=c(-.7,.7))
plot(X, precos.pca$loadings[,2], ylim=c(-.7,.7))
plot(X, precos.pca$loadings[,3], ylim=c(-.7,.7))
plot(X, precos.pca$loadings[,4], ylim=c(-.7,.7))
precos.pca$loadings[,2]
```



O gráfico do primeiro componente é quase constante, indicando que ele representa a média do retorno. O gráfico do segundo já é crescente, indicando a tendência positiva (pois o retorno é positivo) do retorno. O formato da terceira curva indica que ela representa a curvatura da curva de rendimento, enquanto que não dá para retirar algo particularmente interessante da quarta curva, indicando que ela é em maior parte composta de erro.